Донской государственный технический университет

Лабораторная работа № 6

Исследование параметров text-to-image генерации

Вариант 1. Афиша фестиваля робототехники
Число шагов: 1 → 4

Дисциплина: «Искусственный интеллект в креативных технологиях»

Выполнил: Скрыпник Михаил Дмитриевич
Группа: МИК11

Ростов-на-Дону, 2026
Дата эксперимента: 27 октября 2026 года

Фактическое выполнение: локальный Python, Windows, CPU float32. Работа содержит реальные измерения по пяти seed. Среда отличается от рекомендуемой Colab T4 float16; результаты демонстрационного примера не выдаются за собственные.

1. Цель и постановка эксперимента

Цель: установить, как переход с одного на четыре шага SD-Turbo меняет соответствие брифу, энергию границ, контраст и время генерации при неизменных остальных условиях.

Бриф. Концепт афиши фестиваля робототехники: синий и янтарный цвета, светящийся силуэт механической руки, чистая композиция, без текста, логотипов и людей.

Единственный изменяемый фактор: num_inference_steps: A = 1, B = 4. В обоих режимах: 512 × 512, guidance_scale = 0,0, одинаковый запрос, CPU float32 и свежий CPU Generator для каждого вызова. Парная серия seed: 101, 102, 103, 104, 105.

Исходный английский запрос:
editorial poster concept for a robotics festival, glowing mechanical arm silhouette, deep blue and amber palette, clean composition, no text, no logo, no people

Гипотеза, записанная до запуска: Четыре шага повысят энергию границ и время; CLIP останется в пределах ±1,0. Контраст может возрасти.

Время записи: 2026-10-27T15:50:31.463867+03:00. Запись сохранена в configs/preregistration.json; времена начала каждого измерения находятся в манифестах.

Метрика	Практический допуск	Обоснование
CLIP	±1,0 пункта	Меньший сдвиг считаем малым для соответствия брифу.
Энергия границ	±10% среднего A	Отсекает малые изменения резкости.
Контраст	±10% среднего A	Отсекает малое изменение распределения яркости.
Время	±20% среднего A	Замедление свыше 20% существенно для черновиков.

Правило окупаемости: 4 шага оправданы для черновиков, только если CLIP вырастет более чем на 1,0, время вырастет не более чем на 20%, а главный объект останется узнаваемым.

Допуски являются заранее выбранным учебным правилом, а не универсальной нормой. Для энергии границ и контраста слово «улучшение» в классификации означает рост показателя, а эстетическое качество оценивается отдельно.

2. Данные, модели и ход работы

Данные синтетические: один текстовый бриф и сгенерированные изображения. Фотографии реальных людей и чужие знаки в запрос не включены. Изображения рассматриваются как концепты, а не как технически достоверные изображения устройств.

Компонент	Фактическое значение
Генератор	stabilityai/sd-turbo
Ревизия SD-Turbo	b261bac6fd2cf515557d5d0707481eafa0485ec2
Метрика CLIP	openai/clip-vit-base-patch32
Ревизия CLIP	3d74acf9a28c67741b2f4f2ea7635f0aaf6f0268
Среда	Windows-10-10.0.26300-SP0
Python / устройство	3.11.17 / CPU, float32, 4 потока
PyTorch / Diffusers	2.11.0+cpu / 0.40.0
Transformers / NumPy	5.21.0 / 2.4.6
Pillow / Accelerate	12.3.0 / 1.15.0
Внимание / детерминизм	PyTorch SDPA; slicing отключён; deterministic_algorithms=True

Веса SD-Turbo взяты из варианта fp16 закреплённого снимка и приведены к float32 для CPU. CLIP работает в float32. Все условия внутри пары A/B одинаковы, кроме числа шагов. Новый сеанс и другой вычислитель не проверялись.

Протокол. После записи гипотезы загружена SD-Turbo; выполнены прогревы обоих режимов на seed 0. Затем для каждого seed измерены A и B; время включает весь вызов генератора, исключает загрузку модели, сохранение PNG и расчёт метрик. После генерации CLIP оценивает каждое изображение относительно одного английского брифа.

Фрагмент кода:

```
generator = torch.Generator("cpu").manual_seed(seed)
image = pipe(prompt=PROMPT, num_inference_steps=steps,
  guidance_scale=0.0, height=512, width=512, generator=generator).images[0]
```

Лицензии. Для SD-Turbo сохранена лицензия закреплённого снимка; работа использует модель в учебных некоммерческих целях. Для CLIP сохранена MIT License из репозитория OpenAI. Карточки моделей и тексты лицензий находятся в assignment/. Powered by Stability AI.

3. Результаты измерений

Режим	Seed	CLIP	Границы	Контраст	Время, с
A	101	27,3593	0,041666	0,178326	71,39
B	101	30,3497	0,090361	0,257167	127,43
A	102	29,2678	0,041414	0,179453	78,05
B	102	29,6096	0,081238	0,262184	97,51
A	103	32,2888	0,054876	0,176351	80,57
B	103	29,7095	0,121403	0,276400	108,73
A	104	32,3623	0,047434	0,176234	75,73
B	104	27,2742	0,100767	0,256147	107,47
A	105	28,1354	0,044267	0,213237	84,35
B	105	27,1487	0,076507	0,282588	106,45

CLIP = 100 × cos(eI, eT). Яркость Y = 0,299R + 0,587G + 0,114B для RGB/255. Энергия границ: среднее hypot(SobelY, SobelX)/8 с отражением на границе. Контраст: std(Y). Числа в таблицах округлены; JSON и CSV содержат полную точность.

Метрика	A	s(A)	B	Δ=B-A	|Δ|/s	>2s
Сходство CLIP	29,8827	2,3311	28,8183	-1,0644	0,46	нет
Энергия границ	0,0459	0,0056	0,0941	0,0481	8,66	да
Контраст	0,1847	0,0160	0,2669	0,0822	5,14	да
Время, с	78,0169	4,8925	109,5183	31,5014	6,44	да

s - выборочное стандартное отклонение режима A (ddof=1) по пяти seed. Критерий |Δ| > 2s показывает выход среднего сдвига за удвоенный разброс A между seed. Он не является формальным парным тестом и не задаёт вероятность ошибки или p-значение.

Метрика	Изменение, %	Порог в единицах	По допуску
Сходство CLIP	-3,6	1,0000	ухудшение
Энергия границ	104,8	0,0046	улучшение
Контраст	44,5	0,0185	улучшение
Время, с	40,4	15,6034	ухудшение

«Улучшение» энергии границ/контраста обозначает рост соответствующего показателя. Сводный вывод о качестве по этим словам не делается.

4. Сравнительный лист и визуальная оценка



Seed 101: слева A (1 шаг), справа B (4 шага). Исходные изображения 512 × 512; сравнительный лист содержит уменьшенные копии 384 × 384.

Наблюдение для seed 101. В A виден крупный сочленённый манипулятор и дополнительные механические элементы на синем фоне с янтарно-оранжевыми участками. В B общая диагональная композиция сохраняется, контуры становятся толще и темнее, жёлто-чёрные области выразительнее, часть тоновых переходов превращается в плоские пятна. Главный манипулятор узнаваем в обоих режимах. Фон со светлыми точками и дополнительные детали остаются насыщенными: требование чистой композиции выполнено лишь частично.

Проверка главного объекта по всей серии.

Seed	Наблюдение
101	В обоих режимах крупная сочленённая механическая рука занимает центр и правую часть; B усиливает обводки и плоские контрастные области. Дополнительные механизмы и пёстрый фон усложняют композицию.
102	A напоминает целую роботизированную фигуру с несколькими манипуляторами: отдельная рука читается, но не выделена как единственный главный объект. B B центральная сочленённая рука заметнее, изображение более плоское и контурное; сверху остаются обрезанные дополнительные механизмы.
103	В обоих режимах главным объектом стал целый человекоподобный робот, а не отдельная механическая рука. B B линии и сетчатый декоративный фон значительно плотнее и контрастнее. Рост границ здесь включает фоновые узоры и не означает более точного выполнения брифа.
104	В центре обоих кадров сочленённый механический узел с длинной диагональной рукой и дополнительными ответвлениями. B упрощает тоновые переходы и усиливает контуры; зернистый декоративный фон остаётся очень плотным. Рука узнаваема, но композиция не минималистична.
105	Оба режима дают сложную роботизированную фигуру с несколькими длинными руками; отдельный силуэт руки не является единственным главным объектом. B B больше плоских тёмных областей и светлых обводок. Янтарный фон доминирует, глубокий синий выражен слабее, чем в seed 101.

Граница интерпретации. Узнаваемость механического объекта не означает конструктивную достоверность. Визуальная оценка субъективна; несколько механизмов, декоративный фон и случайные отметки могут мешать применению изображения как готовой афиши. Наличие слов no text и no logo в запросе само по себе не гарантирует отсутствие случайных символов.

По этой субъективной оценке рука или крупный сочленённый манипулятор является главным объектом в 2 из 5 кадров A и 3 из 5 кадров B. Полное выполнение брифа всей серией не подтверждено.

5. Намеренная ошибка и её диагностика

Ошибка ожидания: считать, что guidance_scale = 1,0 включает classifier-free guidance и усиливает соответствие запросу. Проверка выполнена отдельно от основного однофакторного эксперимента: seed 101, один шаг, тот же запрос и размер.

Guidance	CFG активен	PNG равен 0,0	PSNR к 0,0
0,0	нет	эталон	∞
1,0	нет	да	Infinity
3,0	да	нет	12,30 дБ



guidance 0,0



guidance 1,0



guidance 3,0

SHA-256 для guidance 0,0 и 1,0:
5a97bb00a00adaf1920e051d99e46a2bb366c811466814d96d17c5448109a7eb

Наблюдение. Для 0,0 и 1,0 совпали байты PNG и пиксели; CFG=False. Для 3,0 CFG=True, изображение изменилось. Полные SHA-256, MSE, PSNR и состояния CFG сохранены в artifacts/guidance_check.json.

Объяснение. В используемом pipeline Diffusers CFG активируется при guidance_scale > 1 и отсутствии отдельной условной проекции времени. При 0,0 и 1,0 здесь используется одинаковая ветвь генерации. Диагностика: вывести pipe.do_classifier_free_guidance сразу после вызова.

Исправление. Для обычной работы SD-Turbo оставить 0,0. Для диагностического изучения значения больше 1 явно отметить выход за рекомендованный режим. Нельзя переносить результат на другие модели с обычным CFG.

6. Анализ, сравнение и вывод

Сходство CLIP. A=29,8827, B=28,8183, Δ=-1,0644 (-3,6%). По допуску: ухудшение; критерий 2s: нет.

Энергия границ. A=0,0459, B=0,0941, Δ=0,0481 (104,8%). По допуску: улучшение; критерий 2s: да.

Контраст. A=0,1847, B=0,2669, Δ=0,0822 (44,5%). По допуску: улучшение; критерий 2s: да.

Время, с. A=78,0169, B=109,5183, Δ=31,5014 (40,4%). По допуску: ухудшение; критерий 2s: да.

Согласование критериев. Ответы критерия 2s и практического допуска различаются для: Сходство CLIP. Это разные вопросы: величина эффекта относительно разброса seed и относительно заранее выбранной полезной величины.

Проверка гипотезы. Рост энергии границ и времени подтверждён. Предположение о нейтральном CLIP не подтвердилось по допуску: снижение 1,064 пункта немного превышает порог 1,0. При удвоении допуска оно станет нейтральным; критерий 2s этого снижения не выделяет. Вывод о CLIP чувствителен к границе допуска.

Чувствительность к допуску. В таблице отмечен выход за порог при уменьшении и увеличении допуска вдвое.

Метрика	0,5 допуска	Исходный	2 допуска
Сходство CLIP	да	да	нет
Энергия границ	да	да	да
Контраст	да	да	да
Время, с	да	да	да

Сопоставление с демонстрацией методички. Ниже приведены опубликованные в методичке значения отдельного GPU-эксперимента; это внешние данные, а не наши измерения.

Метрика	Демо A / B	Наши A / B
Сходство CLIP	30,796 / 30,292	29,8827 / 28,8183
Энергия границ	0,0457 / 0,0920	0,0459 / 0,0941
Контраст	0,1923 / 0,2778	0,1847 / 0,2669
Время, с	0,2854 / 0,5266	78,0169 / 109,5183

Различия допустимы: CPU float32, SDPA и версии среды отличаются от T4 float16. Время разных устройств напрямую не сравнивается; точного воспроизведения чисел GPU не заявляем.

Объяснение. Дополнительные шаги повторно уточняют скрытое представление и могут усилить мелкие структуры и перепады яркости. Это согласуется с ростом границ и контраста, если он наблюдается, но не гарантирует лучшего выполнения брифа. SD-Turbo обучена работать при малом числе шагов; соответствие запросу не обязано монотонно расти. Это интерпретация, а не отдельное измерение.

Вывод. Для быстрых черновиков переход на четыре шага по заранее заданному правилу не окупился. Решение относится к этому брифу и пяти seed; рост границ и контраста сам по себе не подтверждает лучшее качество афиши.

Угрозы валидности. Один бриф, пять seed и одна модель; CLIP не проверяет механику руки, эстетику и точность деталей. Резкость растёт также от шума. Время измерено один раз для каждой пары, зависит от фоновой нагрузки, порядка A→B и состояния CPU. Прогрев снижает, но не устраняет эти факторы. Визуальная оценка субъективна. Для общей рекомендации нужны больше seed, несколько брифов, повторные замеры и слепая экспертная оценка.

7. Ответы на контрольные вопросы (1-5)

1. Почему изменяется один фактор и нужна серия seed?

При изменении нескольких факторов невозможно приписать эффект числу шагов. Одинаковые seed в A и B контролируют начальный шум, а пять seed показывают, насколько результат зависит от случайной композиции. Один seed не описывает разброс.

2. Что означает |Δ| > 2s?

Средний сдвиг превышает удвоенное выборочное стандартное отклонение режима A. Это учебная эвристика заметности на фоне разброса, не формальное доказательство причинности и не p-тест. В нашей серии критерии расходятся для Сходство CLIP.

3. Что измеряет CLIP и зачем английский бриф?

CLIP измеряет косинусную близость векторов изображения и текста, умноженную на 100. Он не оценивает качество афиши целиком. Неизменный английский эталон сохраняет одну цель сравнения; у модели есть ограничения по языкам и длине текста. Это не формула CLIPScore с дополнительным масштабированием.

4. Почему рост энергии границ не доказывает качество?

Модуль градиента растёт и от полезных деталей, и от шума, ореолов, перегруженного фона и артефактов. Поэтому нужна проверка главного объекта, композиции и пригодности результата для афиши.

5. Почему guidance 1,0 совпадает с 0,0?

В данном pipeline CFG включается только при значении больше 1. На seed 101 для 0,0 и 1,0 совпали SHA-256 PNG и пиксели, а pipe.do_classifier_free_guidance=False. При 3,0 флаг True и изображение отличается. Для SD-Turbo рекомендован 0,0; другие модели требуют отдельной проверки.

8. Вопросы (6-10), паспорт и источники

6. Что будет при 768 × 768? Это выход за рекомендуемые 512 × 512: возможны повторяющиеся детали, нарушение композиции и артефакты. В варианте 1 размер не менялся; собственных наблюдений для 768 × 768 нет.

7. Время 0,30 → 0,55 с: изменение? (0,55 − 0,30)/0,30 × 100% = 83,33%. Генерация стала примерно в 1,83 раза дольше.

8. Почему русский запрос сравнивают с английским брифом? Иначе изменятся одновременно изображение и эталон метрики, и сравнение будет отвечать на другой вопрос. Фиксированный эталон проверяет выполнение одного исходного задания. В этом варианте оба запроса английские.

9. Как выбран допуск и что при удвоении? До запуска приняты ±1 пункт CLIP, ±10% для границ и контраста, ±20% времени как границы заметного для черновиков эффекта. Удвоение делает классификацию менее чувствительной; фактические ответы приведены в таблице чувствительности. Критерий 2s от изменения допуска не меняется.

10. Что сохранить для воспроизведения? Ревизии SD-Turbo и CLIP, точный текст запроса, seed 101–105, шаги, guidance, размер, тип вычислений, устройство, версии библиотек, алгоритм внимания, генератор, прогрев, порядок вызовов и формулы метрик. Паспорт: artifacts/passport.json. Полное совпадение времени не ожидается.

Материалы и индивидуальный вклад. Подготовлены локальная адаптация библиотек, реальная серия генераций, расчёт метрик, проверка CFG, визуальная оценка, анализ допуска и отчёт. LR06.ipynb выполнен для независимой проверки сохранённых результатов; повторная генерация доступна через RUN_FULL_EXPERIMENT=True. Исходный журнал генерации сохранён отдельно. При подготовке кода и оформления использовался ИИ-помощник.

Источники.

1. Методические указания «Лабораторная работа № 6. Исследование параметров text-to-image генерации», предоставленный PDF: разделы 2-9 и приложение А. Демо-числа взяты из раздела 6.3.

2. SD-Turbo: карточка закреплённой ревизии; лицензия сохранена в assignment/model_LICENSE.md.

3. CLIP ViT-B/32: карточка закреплённой ревизии; MIT License сохранена в assignment/CLIP_LICENSE.txt.

4. Sauer и др. Adversarial Diffusion Distillation, arXiv:2311.17042. Radford и др. Learning Transferable Visual Models From Natural Language Supervision, arXiv:2103.00020.